

最適化手法を用いた グラフ描画とその初期配置

浜口 広樹, 丸茂直貴, 武田朗子
東京大学 大学院 情報理工学系研究科

2025/5/31


グラフ描画とは

グラフ $G = (V, E)$ (頂点集合 V / 辺集合 E)
グラフ描画は視覚化における重要なタスクの一つ
力学モデル (特に、FR モデル) に基づく描画手法が有名




SNS のフォロー関係
を表すグラフ

Designed by [Freepik](#)



関連性を表す知識グラフ
Google Knowledge Graph や
Obsidian(ノートエディタ)

By [RealKM](#)



論文の引用関係を表すグラフ

By  **CONNECTED PAPERS** ([Link](#))

NetworkX によるグラフ描画


Fruchterman-Reingold (FR) 力学モデルが著名
一般的・直感的・シンプルなグラフ描画を実現

NetworkX  は著名な Python ライブラリ
`nx.draw`: **FR** 力学モデルを用いたグラフ描画

$|V| = 10$: 0.2 sec / 完璧な円形を描画

```
import networkx as nx  
  
G = nx.cycle_graph(10)  
nx.draw(G, node_size=50)
```

✓ 0.2s



NetworkX によるグラフ描画

Fruchterman–Reingold (FR) 力学モデルが著名
一般的・直感的・シンプルなグラフ描画を実現

NetworkX  は著名な Python ライブラリ
`nx.draw`: **FR** 力学モデルを用いたグラフ描画


$|V| = 10$: 0.2 sec / 完璧な円形を描画

$|V| = 20$: 0.2 sec / 捻じれが生じ出す

```
import networkx as nx
```

```
G = nx.cycle_graph(20)  
nx.draw(G, node_size=50)
```

✓ 0.2s




NetworkX によるグラフ描画

Fruchterman–Reingold (FR) 力学モデルが著名
一般的・直感的・シンプルなグラフ描画を実現

NetworkX  は著名な Python ライブラリ
`nx.draw`: **FR** 力学モデルを用いたグラフ描画

$|V| = 10$: 0.2 sec / 完璧な円形を描画
 $|V| = 20$: 0.2 sec / 捻じれが生じ出す
 $|V| = 500$: **11.5 sec** / **壊滅的な描画結果**

```
import networkx as nx  
  
G = nx.cycle_graph(500)  
nx.draw(G, node_size=50)  
✓ 11.5s
```



“捻じれ” がもたらす停滞

捻じれとは、不必要な辺の交差や歪んだグラフ構造を指す

[Veldhuizen, 2007, Cheong and Si, 2018]

→ 特に大規模なグラフ描画において、深刻な問題となる

これを **2つの数理最適化手法によるアプローチ** で解決するのが本研究の目的


Fruchterman–Reingold 力学モデル (従来の解釈)

attractive force (引力) と repulsive force (斥力) が働く [Fruchterman and Reingold, 1991]

$$F_{i,j}^a(d) := \frac{w_{i,j}d^2}{k}, \quad F^r(d) := -\frac{k^2}{d}.$$

力指向グラフ描画はこれらの力の均衡点を単純なシミュレーションで求める


Multilevel Approach という複雑だが強力な手法も併用可能 (GraphViz など) [Hu, 2006]



問題の定式化

従来の解釈: 引力と斥力の均衡点を求めてグラフ描画

$$F_{i,j}^a(d) := \frac{w_{i,j}d^2}{k}, \quad F^r(d) := -\frac{k^2}{d}.$$



これらのスカラーポテンシャル (エネルギー) は次のように定義される [Hosobe, 2012]

$$E_{i,j}^a(d) := \int_0^d F_{i,j}^a(r) dr = \frac{w_{i,j}d^3}{3k}, \quad E^r(d) := \int_\infty^d F^r(r) dr = -k^2 \log d,$$
$$E_{i,j}(d) := E_{i,j}^a(d) + E^r(d).$$

均衡点を求める $\iff f(X)$ の局所最適解を求める (非凸最適化問題)

$$\underset{X \in \mathbb{R}^{2 \times n}}{\text{minimize}} \quad f(X) := \sum_{i < j} E_{i,j}(\|x_i - x_j\|).$$


貢献 1: L-BFGS 法による最適化 (NetworkX に実装を提案)

L-BFGS 法を用いる
無制約問題に対する微分情報を用いた最適化手法

効率的と知られていた
[Hosobe, 2012]

主に実装面での貢献
軽量な実装が特徴
(NetworkX という OSS で
次バージョンより採用予定)

次ページで述べる非有界な
場合に対する**モデル修正**
などを新規に提案



貢献 1: L-BFGS 法による最適化 (非有界に対処するモデル修正)

力学に基づくシミュレーションは、非連結グラフや負辺ありでも動く


しかし、最適化問題としては実は**非有界**となる

不合理な描画結果に!


連結グラフの場合に対する理論的同一性を保ちながら重なりが生じにくい**重力項**を導入した

old version (force) new version (energy)


union
0.05s




negative
0.06s




no edges
13.83s




1.36s



0.90s




2.89s



貢献 2: 座標ニュートン方向を用いた初期配置

数理最適化によるアプローチを更に高速化出来ないか? → 初期配置 (2 つ目の貢献)

焼き鈍し法 [Ghassemi Toosi et al., 2016] よりも、より広く適用出来る方法を提案



貢献 2: 問題の簡略化 (1/2)


初期配置として大まかな解を高速に得たい 元問題の代わりに次を解く:

$$\begin{aligned} & \underset{X \in \mathbb{R}^{2 \times n}}{\text{minimize}} && \sum_{\{i,j\} \in E} \frac{w_{i,j} \|x_i - x_j\|^3}{3k}, \\ & \text{subject to} && x_i \in Q^{\text{hex}} \quad \text{for } 1 \leq i \leq n, \\ & && x_i \neq x_j \quad \text{for } 1 \leq i < j \leq n. \end{aligned}$$


where

$$Q^{\text{hex}} := \left\{ \left(q + \frac{1}{2}r, \frac{\sqrt{3}}{2}r \right) \mid q \in \mathbb{Z}, r \in \mathbb{Z} \right\}.$$

(1)



placements: X_1, X_2, X_3



この導出理由: 元問題 $\text{minimize } f(X)$ においてまず $f(X)$ を $E_{i,j}^a$ と E^r に分離する

$$\underset{X \in \mathbb{R}^{2 \times n}}{\text{minimize}} \quad \sum_{\{i,j\} \in E} \frac{w_{i,j} \|x_i - x_j\|^3}{3k} - \sum_{i < j} k^2 \log \|x_i - x_j\|.$$

貢献 2: 問題の簡略化 (2/2)

先行研究 [Ghassemi Toosi et al., 2016] に従い、 x_i の位置を離散点集合 Q に固定する:

$$\begin{aligned} & \underset{X \in \mathbb{R}^{2 \times n}}{\text{minimize}} && \sum_{\{i,j\} \in E} \frac{w_{i,j} \|x_i - x_j\|^3}{3k} - \sum_{i < j} k^2 \log \|x_i - x_j\|, \\ & \text{subject to} && x_i \in Q \quad \text{for } 1 \leq i \leq n, \\ & && x_i \neq x_j \quad \text{for } 1 \leq i < j \leq n. \end{aligned}$$

$|\{\{i, j\} \text{ s.t. } \{i, j\} \in E\}| = |E| \ll |\{\{i, j\} \text{ s.t. } i < j\}| = \mathcal{O}(|V|^2)$. 第二項を落としたい
 $\|q_i - q_j\| \geq \epsilon$ ($q_i, q_j \in Q, q_i \neq q_j$) を満たす Q を取ると、第二項の影響を抑えられる

$$\begin{aligned} & \underset{X \in \mathbb{R}^{2 \times n}}{\text{minimize}} && f^a(X) := \sum_{\{i,j\} \in E} \frac{w_{i,j} \|x_i - x_j\|^3}{3k}, \\ & \text{subject to} && x_i \in Q \quad \text{for } 1 \leq i \leq n, \\ & && x_i \neq x_j \quad \text{for } 1 \leq i < j \leq n. \end{aligned}$$

Q としては六方最密構造を用いる

貢献 2: ここまでのまとめ

元々の問題は以下であった:


$$\underset{X \in \mathbb{R}^{2 \times n}}{\text{minimize}} \quad f(X) := \sum_{i < j} E_{i,j}(\|x_i - x_j\|) = \sum_{\{i,j\} \in E} \frac{w_{i,j} \|x_i - x_j\|^3}{3k} - \sum_{i < j} k^2 \log \|x_i - x_j\|.$$

次のように簡略化すること高速化を図る:

$$\underset{X \in \mathbb{R}^{2 \times n}}{\text{minimize}} \quad f^a(X) := \sum_{\{i,j\} \in E} \frac{w_{i,j} \|x_i - x_j\|^3}{3k}$$

subject to $x_i \in Q^{\text{hex}}$ for $1 \leq i \leq n$,
 $x_i \neq x_j$ for $1 \leq i < j \leq n$.

次以降で簡略化後の問題を解く方法を説明する



貢献 2: 提案アルゴリズムの基礎 – 確率的座標降下法

$f: \mathbb{R}^n \rightarrow \mathbb{R}$ を狭義凸関数とする。 x_0 における 2 次近似は次のように表される:

$$f(x) \approx f(x_0) + \nabla f(x_0)^\top (x - x_0) + \frac{1}{2}(x - x_0)^\top \nabla^2 f(x_0)(x - x_0).$$

最小値 x^* は次を満たす:

$$\begin{aligned} \nabla f(x_0) + \nabla^2 f(x_0)(x^* - x_0) &= 0 \\ \iff x^* &= x_0 - \nabla^2 f(x_0)^{-1} \nabla f(x_0). \quad (\text{ニュートン方向}) \end{aligned}$$

これは優れた更新則だが、ニュートン方向の計算は**非常に高コスト**...

我々は **確率的座標降下法** を **座標ニュートン方向** と組み合わせて使用する
 $f_i(x_i)$ を i 番目の座標 (ランダムに選択) に制限した関数とする
座標ニュートン方向: $d_i = -\nabla^2 f_i(x_i)^{-1} \nabla f_i(x_i)$ ← **低コスト! 計算可能!**

貢献 2: 提案アルゴリズム – 更新則

f_i^a に限定すると凸関数になることに注意する。 通常の更新則:


$$x_i^{\text{new}} \leftarrow x_i - \nabla^2 f_i^a(x_i)^{-1} \nabla f_i^a(x_i).$$

x_i^{new} は六角格子 Q^{hex} に含まれるとは限らず、 Q^{hex} 上の最近点に丸める必要がある
経験的に、ランダムノイズを加えることが効果的である (焼き鈍し法と同様の原理)

$$x_i^{\text{new}} \leftarrow \text{round}(x_i - \nabla^2 f_i^a(x_i)^{-1} \nabla f_i^a(x_i) + t \cdot \text{rand}),$$



$\text{round}(\hat{x})$: $\hat{x}$ を Q^{hex} 上の最も近い点に割り当てる操作

$t \cdot \text{rand}$ は長さ t のランダムベクトル、徐々に 0 に近づく



実験結果 1/2

jagmesh1 ($|V| = 936, |E| = 2664, \text{sparsity} = 0.609\%$) Figures are at 50 iterations.



dwt_1005 ($|V| = 1005, |E| = 3808, \text{sparsity} = 0.755\%$) Figures are at 100 iterations.







Figure: “BEST” は提案手法の 500 反復目の状態

実験結果 2/2

dwt_2680 ($|V| = 2680, |E| = 11173, \text{sparsity} = 0.311\%$) Figures are at 150 iterations.



3elt ($|V| = 4720, |E| = 13722, \text{sparsity} = 0.123\%$) Figures are at 150 iterations.





Figure: “BEST” は提案手法の 500 反復目の状態

最後に

まとめ

Fruchterman-Reingold レイアウトへの数値最適化によるアプローチを提案

貢献 1: L-BFGS 法を用いた描画法の OSS 実装

貢献 2: 座標ニュートン方向を用いた効率的な初期配置の計算方法の提案

今後の展望

グラフ同型判定問題は、2つのグラフの直和を対称に描画するのと似た問題
[Eades, 1984, Klus and Gelß, 2023] 提案手法と似た考えを応用出来ないか?

Graph の Sparsity 自体をもっと効率的に L-BFGS 法で使えないか?

より広く、L-BFGS 法自体を更に改善させることは出来ないか? (現在の我々の研究)

Reference I

- Se-Hang Cheong and Yain-Whar Si. Snapshot Visualization of Complex Graphs with Force-Directed Algorithms. In *2018 IEEE International Conference on Big Knowledge (ICBK)*, pages 139–145, January 2018. doi: 10.1109/ICBK.2018.00026. URL <https://ieeexplore.ieee.org/document/8588785/?arnumber=8588785>.
- Peter Eades. A heuristic for graph drawing. *Congressus numerantium*, 42(11):149–160, 1984.
- Thomas M. J. Fruchterman and Edward M. Reingold. Graph drawing by force-directed placement. *Software: Practice and Experience*, 21(11):1129–1164, 1991. ISSN 1097-024X. doi: 10.1002/spe.4380211102. URL <https://onlinelibrary.wiley.com/doi/abs/10.1002/spe.4380211102>.
- Farshad Ghassemi Toosi, Nikola S. Nikolov, and Malachy Eaton. Simulated Annealing as a Pre-Processing Step for Force-Directed Graph Drawing. In *Proceedings of the 2016 on Genetic and Evolutionary Computation Conference Companion, GECCO '16 Companion*, pages 997–1000. Association for Computing Machinery, July 2016. ISBN 978-1-4503-4323-7. doi: 10.1145/2908961.2931660. URL <https://dl.acm.org/doi/10.1145/2908961.2931660>.

Reference II

- Hiroshi Hosobe. Numerical optimization-based graph drawing revisited. In *2012 IEEE Pacific Visualization Symposium*, pages 81–88, 2012. doi: 10.1109/PacificVis.2012.6183577.
- Yifan Hu. Efficient, high-quality force-directed graph drawing. *The Mathematica journal*, 10: 37–71, 2006. URL <https://api.semanticscholar.org/CorpusID:14599587>.
- Stefan Klus and Patrick Gelß. Continuous optimization methods for the graph isomorphism problem, November 2023. URL <http://arxiv.org/abs/2311.16912>.
- Todd L. Veldhuizen. Dynamic Multilevel Graph Visualization, December 2007. URL <http://arxiv.org/abs/0712.1549>.